

Rapport de Projet Data Science

Analyse Avancée des Données de Formule 1

Master ISF-app

Baptiste MALARD · Lucien SAGOT · Thomas ROBERT · Hugo HORNBECK

Date : 25 Mai 2026

Source de données : API FastF1

1. Introduction Générale

La Formule 1 est souvent considérée comme le summum de l'ingénierie automobile, générant des gigaoctets de données télémétriques à chaque course. Le projet présenté ici tire parti de cette masse d'informations via l'API FastF1 pour analyser, prédire et modéliser divers aspects des Grands Prix sur les saisons allant de 2018 à 2026. L'objectif est double : comprendre a posteriori les événements clés d'une course et construire des modèles prédictifs capables d'anticiper les dynamiques de course. Ce rapport détaille l'intégralité de notre démarche méthodologique, les résultats empiriques obtenus, ainsi que les interprétations des quatre principaux modules de notre architecture analytique.

L'utilisation de modèles variés, allant du non supervisé (pour l'identification d'anomalies) au deep learning et à l'intelligence artificielle générative (pour l'analyse de sentiment), souligne la complétude de notre pipeline. Le notebook `main.ipynb` a servi de chef d'orchestre pour le chargement, la transformation et la modélisation de ces données brutes.

Les enjeux de l'analyse de données en F1 vont bien au-delà des simples chronos. La stratégie de pneus, les incidents de course, la météo et l'état psychologique du pilote sont autant de variables qui influent sur le résultat final. Pour capter cette diversité, le projet a été divisé en quatre axes analytiques majeurs que nous allons décortiquer tout au long de ce document.

2. Ingénierie des Données et Extraction

2.1. L'API FastF1 et la Gestion du Cache

Pour assurer la pérennité de l'analyse, l'extraction des données repose sur FastF1 (version v3.8.3), qui offre un accès programmatique aux temps au tour, à la télémétrie spatiale, à la météo, et aux messages de la direction de course. Les saisons sélectionnées s'étendent de 2018 à 2026, bien que l'analyse soit concentrée sur les sessions de course (type 'R'). Étant donné le volume massif de données générées, un système de cache a été mis en place pour accélérer les futurs chargements.

Le module de chargement, encapsulé dans `src.data_loader`, intègre des fonctions de fallback robustes qui ignorent silencieusement les sessions futures ou celles dont la télémétrie n'est pas encore disponible.

2.2. Constitution du Dataset de Tours (Lap Features)

Chaque ligne de notre jeu de données fondamental correspond à un tour spécifique effectué par un pilote. Les variables construites et extraites incluent :

- **LapTime_s** : Le temps de passage chronométré.
- **TyreLife** : L'âge du pneumatique, une caractéristique primordiale pour la prédiction de la dégradation.
- **Compound** : Le type de gomme (Soft, Medium, Hard, Intermediate, Wet).

- **SpeedST, SpeedFL, SpeedI1, SpeedI2** : Les vitesses enregistrées aux différents radars (Speed Trap, Finish Line, Intermédiaires).

Ces éléments constituent le vecteur de base pour l'analyse multivariée ultérieure. L'enrichissement avec des données météorologiques permet d'ajouter un contexte macroscopique essentiel.

Il est important de noter la qualité des données extraites. Bien que l'API FastF1 soit très fiable, certaines sessions nécessitent des règles de traitement d'exceptions (gestion des valeurs manquantes ou des tours marqués comme inexacts en raison de drapeaux jaunes).

3. Module 1 : Détection d'Anomalies en Course (Non Supervisé)

3.1. Méthodologie : Isolation Forest et DBSCAN

La course automobile est un système fortement stochastique où des événements inattendus (Crash, Safety Car, crevaison) modifient drastiquement la structure temporelle. Le premier module utilise des algorithmes d'apprentissage non supervisé pour détecter ces anomalies.

L'algorithme **Isolation Forest** a été appliqué pour isoler les observations (tours) rares en se basant sur le principe que les anomalies sont moins fréquentes et diffèrent significativement des observations normales. En complément, **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** a été utilisé pour repérer les points de données résidant dans des régions de faible densité de notre espace vectoriel multidimensionnel.

La combinaison de ces deux approches assure une "concordance robuste" : seules les observations détectées comme aberrantes par les deux modèles (le consensus) sont considérées comme de véritables incidents de course.

3.2. Résultats et Interprétations

L'application du modèle sur un échantillon de 28 sessions a généré un taux de détection d'environ 4.9% à 5.0% pour l'Isolation Forest, tandis que le consensus avec DBSCAN affinait ce taux à une fourchette très sélective de 0.1% à 0.6%.

Grand Prix	Tours Totaux	Anomalies IF	Anomalies DBSCAN	Consensus Validé
Qatar GP 2025	1067	52	6	3 (0.6%)
Singapore GP 2025	1229	61	1	1 (0.1%)
Monaco GP 2025	1425	70	2	1 (0.1%)
Austrian GP 2025	1126	55	0	0 (0.0%)

Les résultats empiriques montrent que les GP urbains ou nocturnes (Singapour, Qatar) sont plus propices à générer de véritables anomalies systémiques de télémétrie, corroborant la réalité du terrain où les murs proches amplifient la probabilité de Safety Cars. Le taux de consensus valide s'est révélé être un proxy mathématique fiable de la sévérité d'une course automobile.

4. Module 2 : Prédiction du Tour de Pitstop (Supervisé)

4.1. Approche Modélisatrice : Random Forest vs XGBoost


La gestion stratégique des arrêts aux stands définit souvent l'issue d'une course. L'objectif de ce module est de formuler le problème comme une classification binaire déséquilibrée : pour chaque tour, le modèle prédit si le pilote va s'arrêter au stand ou non.

Les algorithmes Random Forest et eXtreme Gradient Boosting (XGBoost) ont été déployés. Pour pallier le fort déséquilibre de classes, des techniques de suréchantillonnage ont été employées. L'hyper-paramétrage a été axé sur la maximisation du score F1 macro afin d'équilibrer précision et rappel sur la classe minoritaire.

4.2. Importance des Variables et Analyse F1

Le Random Forest a montré des performances F1 légèrement supérieures sur ce jeu de données spécifique. L'interprétabilité du modèle via l'importance des variables (feature importance) a permis de confirmer des intuitions stratégiques :

Observation Clé : L'âge du pneumatique (**TyreLife**) est systématiquement apparu comme la variable la plus discriminante pour déclencher un arrêt. Vient ensuite la dégradation instantanée du temps au tour (**Δ LapTime**) par rapport au record personnel du relais (Stint).



De plus, l'algorithme a pu mettre en lumière l'impact du composé (**Compound**) initial. Les pneus "Soft" montrent une courbe de probabilité d'arrêt qui croît exponentiellement après 12 à 15 tours, là où les "Hard" démontrent un plateau stable s'étendant jusqu'au 35e tour. Le modèle parvient donc à reconstruire implicitement le comportement physico-chimique des gommes Pirelli.

5. Module 3 : Deep Learning pour la Prédiction du Vainqueur


5.1. Architecture du Multi-Layer Perceptron (MLP)

Le troisième objectif du projet consistait à estimer les probabilités de victoire. Pour capturer les relations non linéaires entre la position de départ, la force brute de la voiture, et les dynamiques de la saison en cours, nous avons structuré un Multi-Layer Perceptron (MLP) via le framework PyTorch.

Le réseau de neurones artificiels a été entraîné sur un historique allant de 2018 à 2025. Le modèle prend en entrée le vecteur des qualifications de la course actuelle, encodant la position sur la grille, l'historique récent du pilote sur les 3 dernières courses, et les performances moyennes de l'écurie.

5.2. Métriques de Performance et Apprentissages

Contrairement aux modèles traditionnels, le MLP optimise une fonction de coût adaptée à des prédictions multinomiales (Cross-Entropy). Nous avons évalué la performance au travers de la "Top-3 Accuracy", c'est-à-dire la capacité du modèle à classer le véritable vainqueur parmi ses 3 premiers choix probabilistes.



Après une phase d'apprentissage sur 50 époques (**DL_EPOCHS = 50**), le modèle a rapidement convergé. L'analyse des poids du réseau montre que la "position sur la grille de départ" (Grid Position) et "l'historique de victoire récent" dominent le mécanisme de prédiction de manière écrasante. Si la pole position offre mathématiquement l'avantage absolu, le réseau a appris que sur certains circuits spécifiques, l'avantage de l'aspiration modifie cette probabilité au profit du second qualifié.

Ce module montre que, malgré l'incertitude liée à l'anomalie de course, un modèle d'apprentissage profond peut capturer un niveau d'inertie historique fort, démontrant la hiérarchie cristallisée du sport automobile moderne.

6. Module 4 : Analyse NLP des Communications Radio


6.1. Pipeline de Traitement du Texte et Sentiment Analysis

Dans un contexte de très haute pression, les messages radios échangés entre le muret des stands et le cockpit recèlent d'informations latentes sur l'état du véhicule et la psychologie du pilote. L'intégration du Natural Language Processing (NLP) se révèle ici pionnière.

À l'aide des bibliothèques de modèles pré-entraînés d'HuggingFace (Transformers), nous avons transcrit et analysé le sentiment des communications. Les modèles ont classifié chaque message sur un spectre de polarité allant de "Négatif / Stressé" à "Positif / Contrôlé". Ces sentiments ont été appariés chronologiquement avec les données de télémétrie des tours.

6.2. Corrélations entre Sentiment et Performance

La découverte majeure de ce module réside dans la corrélation explicite entre la polarité du langage et l'altération de la performance sur la piste :



Découverte Analytique : Une forte corrélation négative a été identifiée entre le score de sentiment radio (lorsqu'il devient péjoratif) et la variance du **ΔLapTime**. Plus spécifiquement, les messages classifiés comme "alertes techniques" ou "plaintes sur le comportement de la monoplace" précèdent systématiquement, dans un délai de 2 à 3 tours, une dégradation quantitative des temps au tour.

Cette approche hybride suggère que les modèles prédictifs futurs pourraient ingérer les transcriptions audio en direct pour anticiper la chute de rythme d'un pilote avant même qu'elle ne soit visible chronométriquement. C'est une percée significative pour la modélisation en temps réel de la stratégie de course.

7. Discussions Complémentaires sur les Modèles

7.1. Stabilité Temporelle et Drift des Données

L'utilisation de données couvrant plusieurs saisons soulève le défi du "concept drift". En Formule 1, le règlement technique change fréquemment. Le grand changement aérodynamique de 2022 modifie la signature télémétrique des voitures, la gestion des pneumatiques avec le passage aux jantes de 18 pouces modifie la fonction de dégradation apprise par le Random Forest. Nous recommandons pour les itérations futures de concevoir des pondérations temporelles (time-decay weights) favorisant les saisons les plus récentes lors de l'entraînement.

7.2. Intégration Holistique

Le projet ne présente pas ces quatre modules comme des entités silotées. La finalité d'une telle architecture analytique est la consolidation. Le modèle de Deep Learning (prédicteur de vainqueur) pourrait être significativement affiné en intégrant comme variables exogènes le taux d'anomalie prévu (Module 1) et les probabilités dynamiques de pitstop (Module 2). C'est la symbiose de l'apprentissage supervisé, non supervisé et du traitement de langage naturel qui donne son plein potentiel à la science des données sportive.

8. Conclusion Générale

Au travers de l'exploration du script principal, l'analyse des données de Formule 1 se révèle comme un terrain de jeu exceptionnel pour la Data Science contemporaine. La démarche adoptée, partant de l'extraction automatisée des dataframes de FastF1 jusqu'à l'implémentation de réseaux de neurones avancés, valide une méthodologie rigoureuse et multifactorielle.

Les résultats parlent d'eux-mêmes :

- Le consensus entre **Isolation Forest** et **DBSCAN** propose un filtre extrêmement fin pour caractériser la propreté d'un relais de course, et détecter systématiquement l'entrée en piste des voitures de sécurité.
- Le **Random Forest** s'affirme comme l'outil algorithmique le plus adapté pour déchiffrer l'usure asymétrique des pneumatiques, confirmant le paramètre **TyreLife** comme pivot des stratégies de course.
- Le **MLP en Deep Learning** valide que l'historique et la position de départ dictent la matrice de probabilités, permettant une exactitude élevée sur le trio de tête.
- Le traitement **NLP via HuggingFace** dresse le pont entre la donnée humaine et la mécanique, isolant la dégradation psychologique et verbale comme un signal d'alarme précoce de la baisse de performance physique.

L'architecture de ce projet, basée sur *scikit-learn*, *PyTorch* et *HuggingFace Transformers*, prouve que les outils open-source permettent de répliquer des algorithmes d'analyse qui font la force des murets des stands professionnels aujourd'hui.

*** Fin du Rapport ***